

面向双耳 360° DOA 分类的结构化线索分解与紧凑融合

作者姓名 (待补充)

作者单位与联系邮箱 (待补充)

摘要

双耳 360° 定位需要同时利用耳间差异与方向相关频谱结构,但这些信息具有不同的物理含义和统计形式:ILD/IPD 直接描述左右耳差异,局部耳间相干性描述两耳观测的一致程度,而双耳幅度谱还保留源频谱与 HRTF 频谱着色。紧凑模型若在高维输入端统一处理这些异质信息,有限容量将同时承担差异提取、上下文建模和线索整合。本文据此提出一种“先保持结构、后低维融合”的 72 类静态 DOA 网络。共享编码器提取两耳幅度谱表示,并以均值、带符号差值和绝对差值显式组织双耳关系;两个低维分支分别编码 ILD/IPD 方向线索值与局部相干性,随后由单层 BiGRU 和注意力池化聚合。在当前 7,776 样本的 KEMAR 测试协议上,模型以 0.153 M 参数和 0.391 GFLOPs 获得 96.51% 准确率与 2.46° 环形 MAE。消融结果表明,幅度谱上下文在显式线索之外仍提供互补信息,独立相干性编码与分离式线索编码也优于对应的移除或合并变体。结果支持按线索结构分配有限建模能力可形成有竞争力的性能-效率权衡。

关键词— 双耳声源定位, 到达方向估计, 双耳空间线索, 耳间相干性, 轻量神经网络

1. 引言

双耳声源定位根据左右耳信号估计声源方向,是空间音频、听觉辅助与机器人听觉的重要基础。本文聚焦静态单说话人的完整水平面定位:输入为 2 秒双通道语音,输出为覆盖 $[-180^\circ, 180^\circ]$ 的 72 类片段级方位预测。该任务并非普通的 72 类识别,因为类别首尾在几何上相邻,且两耳观测同时受到头部遮挡、耳廓滤波、反射声与背景噪声影响;模型既要命中离散方向,也要控制圆周上的大角度错误与计算成本。

双耳线索在退化条件下不同步失效。ILD 和 IPD 分别刻画两耳幅度比与相位关系,但反射声会将直达声与延迟副本叠加,加性噪声也会以不同强度污染各时频区域 [1, 2]。若只观察耳间差异,前后方向还可能产生相近观测,即经典的锥形混淆;区分它们需要结合耳廓与头部引入的方向相关频谱着色 [1]。因此,显式耳间差异、局部两耳一致性和幅度谱上下文承担相关但不同的角色。

现有方法可直接从波形或完整时频表示学习空间映射 [3],也可先构造 GCC-PHAT、ILD/IPD 或相对传递函数等物理线索 [4, 5]。高容量时频网络减少手工假设,但计算随频率分辨率、序列长度和隐藏维度增长;把全部特征沿通道维直接拼接,则要求同一编码器同时处理频谱结构、方向差异和相干性。这里不能未经对照断言统一编码必然失败,真正可检验的问题是:在紧凑预算下,是否应先与线索结构匹配的低成本路径编码,再进行融合?

本文将有限容量分配给三种结构。两耳幅度谱先由共享编码器映射到可比较空间,再构造交换不变的均值和绝对差值,以及交换变号的带符号差值。方向线索分支编码 ILD、 $\sin(\text{IPD})$ 与 $\cos(\text{IPD})$,避免直接相位在 $-\pi$ 与 π 处的数值跳变;相干性分支则保留归一化互谱中不同于线索取值的信息。三路表示不执行显式门控或置信度校准,而是在 112 维特征层融合后由单层 BiGRU 聚合。

现有证据支持三点贡献: (1) 给出一种 0.153 M 参数、0.391 GFLOPs 的结构化紧凑网络,在当前静态 KEMAR 协议上获得 96.51% 准确率和 2.46° 环形 MAE; (2) 仅保留显式线索的变体仍达到 95.95% 准确率,而完整模型将 MAE 由 2.94° 降至 2.46°,支持幅度谱上下文提供互补证据; (3) 移除相干性或合并线索编码均增加 MAE,支持先保持线索结构、再融合的设计判断。本文不声称绝对精度最优,也不将结论外推到未见 HRTF、真实录音或移动声源。

2. 相关工作

传统双耳定位主要利用差异线索与频谱线索。双耳时间差、IPD 和 ILD 描述声波到达两耳的时间、相位和能量差异 [1],GCC-PHAT 则通过跨通道相关峰估计传播时延 [4]。这些线索具有物理解释,但单凭耳间差异并不总能消除前后混淆;混响和扩散噪声还会使观测偏离直达声条件。耳间相干性是归一化互谱幅度的一类统计量,可描述局部两耳关系的一致程度,但其数值不天然等于校准的可靠概率 [2]。

数据驱动方法使用卷积、循环或端到端结构学习双耳信号到方向的映射。Vecchiotti 等直接从原始波形学习双耳定位 [3],Tokala 等以 GCC-PHAT 和卷积循环网络处理噪声语音定位 [5]。本文实现 SDEL-style、FN-SSL-style、DP-RTF-style 和 BiL-style 四类项目内适配模型;这些名称不代表原文官方结果。与统一高维建模或只使用显式线索不同,本文保留可解释的 ILD/IPD,同时用共享幅度谱编码补充上下文,并把统一时序建模推迟到低维融合之后。研究目标是验证这种容量分配的性能-效率权衡,而非宣称绝对精度超过全部基线。

3. 所提方法

图 1 给出整体结构。方法遵循三项原则:对同类型的左右耳幅度谱共享编码;对已显式计算的方向线索先压缩频带、再低成本建模;对取值空间不同的 ILD/IPD 与相干性分别编码,最后统一聚合。该结构先验是否有效由移除与合并消融检验,而不由模块命名预设。

3.1. 任务定义与双耳特征

设左右耳波形为 $x_L, x_R \in \mathbb{R}^N$, 其复数短时傅里叶变换为 $X_L(t, f)$ 和 $X_R(t, f)$ 。标签 $y \in \{0, \dots, 71\}$ 对应固定方位

$$\theta_y = -180^\circ + 5^\circ y. \quad (1)$$

模型输出 72 维 logits, 不执行连续角度回归。两耳幅度谱上下文输入为 $M_e = \log(|X_e| + \epsilon)$, $e \in \{L, R\}$ 。显式方向线索定义为

$$D = 20 \log_{10} \frac{|X_L| + \epsilon}{|X_R| + \epsilon}, \quad (2)$$

$$\Phi = \angle(X_L X_R^*), \quad \mathbf{Q}_v = [D, \sin \Phi, \cos \Phi]. \quad (3)$$




Fig. 1. 所提结构化线索分解网络。幅度谱上下文、方向线索值与相干性分别编码，在 112 维特征层拼接后进行时序聚合。右侧给出共享轻量幅度谱编码器的单个阶段。

用 $\sin \Phi$ 和 $\cos \Phi$ 表示 IPD，可避免物理相邻的 $-\pi$ 与 π 在标量轴上发生跳变。局部耳间相干性为

$$C = \frac{|S\{X_L X_R^*\}|}{\sqrt{S\{|X_L|^2\}S\{|X_R|^2\}} + \epsilon}, \quad (4)$$

其中 S 为采用反射填充的 5×3 频率-时间局部平均， C 最终截断至 $[0, 1]$ 。该归一化互谱统计不同于相位取值或幅度比；本文将这种差异作为独立编码的动机，而不把 C 解释为校准概率。

3.2. 幅度谱上下文流

幅度谱上下文流保留显式 ILD/IPD 没有完整表达的信息。单耳对数幅度谱既包含源谱包络，也包含 HRTF、房间和噪声造成的频谱着色，因而不是“纯内容特征”。如图 1 所示，同一轻量编码器 E_c 处理左右耳对数幅度谱：

$$\mathbf{F}_L = E_c(M_L), \quad \mathbf{F}_R = E_c(M_R), \quad \mathbf{F}_e \in \mathbb{R}^{T \times 64}. \quad (5)$$

E_c 包含通道数为 16、24 和 32 的三个阶段；每阶段由 1×1 逐点卷积、 3×3 深度卷积、步长 (1, 2) 的 1×3 深度卷积及 1×1 逐点卷积组成，仅沿频率轴降采样。自适应频率平均池化与线性投影产生 64 维逐帧表示。共享权重不仅减少参数，也把 $\mathbf{F}_L$ 和 $\mathbf{F}_R$ 置于同一特征坐标系，使逐维关系具有可比基础；由于没有非共享编码器对照，本文不声称共享本身必然提高精度。两耳表示通过确定性关系组合：

$$\mathbf{R}_c = \left[\frac{\mathbf{F}_L + \mathbf{F}_R}{2}, \mathbf{F}_L - \mathbf{F}_R, |\mathbf{F}_L - \mathbf{F}_R| \right]. \quad (6)$$

这些关系具有明确的耳交换行为：均值和绝对差值保持不变，带符号差值改变符号。因此，表示同时暴露共同成分、差异强度与左右方向性，而无需后续网络先从任意拼接中重新构造这些基础关系。拼接结果经线性层、层归一化、ReLU 和 dropout 投影为 $\mathbf{H}_c \in \mathbb{R}^{T \times 80}$ 。本文只验证整个上下文流的作用，尚未证明三个关系项分别不可替代或模型具备严格耳交换等变性。

3.3. 线索分支、时序融合与目标函数

ILD/IPD 已由左右耳复谱直接计算，线索分支无需重新发现两耳差异，而只需整合其频率与时间分布。方向线索值和相干性先分别将 257 个频点平均池化为 16 个频带，再经过两层核大小为 3 的一维时间卷积，输出 $\mathbf{H}_v \in \mathbb{R}^{T \times 24}$ 和 $\mathbf{H}_r \in \mathbb{R}^{T \times 8}$ 。这种先压缩频率、后执行时序卷积的顺序限制了计算开销；但当前没有频带数对照，不能声称 16 带划分本身提高抗噪性。相干性单独编码是因为归一化互谱幅度与 ILD/IPD 的取值空间不同，而不是预先把它定义为“可信/不可信”标签。实现仅拼接 $\mathbf{H}_v$ 与 $\mathbf{H}_r$ ，不利用相干性生成门控或显式重标定方向线索。三路表示经层归一化与 dropout 得到

$$\mathbf{Z} = \text{Drop}(\text{LN}([\mathbf{H}_c, \mathbf{H}_v, \mathbf{H}_r])) \in \mathbb{R}^{T \times 112}. \quad (7)$$

融合被推迟到各分支压缩为帧级表示之后，因此时序头处理 112 维输入而非完整多通道时频平面。单层 BiGRU 在每个方向使用 80 个隐藏单元；双向建模适用于当前整段可见的离线分类，但不满足因果实时约束。两层打分网络 $g(\cdot)$ 计算注意力权重 $a_t = \exp(g(\mathbf{u}_t)) / \sum_j \exp(g(\mathbf{u}_j))$ ，并以 $\bar{\mathbf{u}} = \sum_t a_t \mathbf{u}_t$ 完成片段级聚合。训练损失为

$$\mathcal{L} = \text{CE}_{\text{LS}}(\mathbf{o}, y) + 0.3 \text{CE}(\mathbf{o}_{\text{fb}}, y_{\text{fb}}), \quad (8)$$

其中主任务标签平滑系数为 0.1，前后辅助头仅用于训练；本文没有辅助头开关消融，故不将其列为独立贡献。

4. 实验

4.1. 数据、设置与指标

静态双耳数据由 LibriSpeech 语音 [6]、MIT KEMAR HRTF[7] 和 SofaMyRoom 房间模拟器 [8] 生成，并叠加 DEMAND 场景噪声 [9]。训练、验证和测试集分别包含 36,000、7,200 和 7,776 条 2 秒样本。训练与验证噪声为 TMETRO、PCAFETER 和 OOFFICE，SNR 从 $[-10, 10]$ dB 均匀采样；

Table 1. 不同 SNR 下的静态定位结果。每项为三次运行平均 Accuracy (%) / 环形 MAE ($^{\circ}$)；不包含 clean 条件。

方法	10 dB	5 dB	0 dB	-5 dB	-10 dB
所提模型	98.89 / 0.87	98.56 / 1.37	97.33 / 2.12	94.42 / 3.63	90.15 / 6.30
SDEL-style	99.07 / 1.20	99.05 / 0.92	97.99 / 1.74	95.47 / 3.44	91.77 / 5.35
FN-SSL-style	98.71 / 1.22	98.61 / 1.29	97.38 / 2.11	95.45 / 2.88	91.20 / 6.04
DP-RTF-style	98.05 / 2.59	97.25 / 3.07	95.99 / 4.33	94.39 / 5.21	89.09 / 7.51
BiL-style	97.81 / 2.33	96.63 / 3.59	94.80 / 4.66	91.05 / 7.51	84.67 / 12.74

Table 2. 复杂度与完整测试集结果。定位指标为三次运行均值。

方法	参数/M	MACs/G	FLOPs/G	Acc./%	MAE/ $^{\circ}$
所提模型	0.153	0.195	0.391	96.51	2.46
SDEL-style	0.926	0.701	1.402	97.18	2.18
FN-SSL-style	0.659	32.843	65.687	96.75	2.33
DP-RTF-style	0.877	4.107	8.215	95.49	4.22
BiL-style	0.865	1.559	3.117	93.97	5.41

Table 3. 完整测试集上的消融结果 (均值 $\pm$ 总体标准差)。

变体	Accuracy/% $\uparrow$	MAE/ $^{\circ}$ $\downarrow$
完整模型	96.51$\pm$0.10	2.46$\pm$0.06
移除幅度谱上下文流	95.95 $\pm$ 0.24	2.94 $\pm$ 0.16
移除相干性分支	95.96 $\pm$ 0.14	2.95 $\pm$ 0.03
合并线索编码器	96.16 $\pm$ 0.18	3.05 $\pm$ 0.19

测试使用未见的 TBUS、NPARK 和 SPSQUARE，并包含 clean、10、5、0、-5 和 -10 dB。测试覆盖六个固定房间，目标 RT60 为 0.30–0.80 秒，声源距离约 1–2 米。所有集合均使用同一 KEMAR，因此不评估跨 HRTF 泛化。

输入采样率为 16 kHz，STFT 使用 512 点 DFT、400 点 Hann 窗和 160 点帧移。模型使用 AdamW，初始学习率 5×10^{-4} 、权重衰减 10^{-4} 、batch size 64、dropout 0.2，余弦调度最低学习率 10^{-5} ，最多 100 个 epoch，早停耐心值 15。主结果和消融报告随机种子 42、43 和 44 的均值；FN-SSL-style 三次运行的辅助头设置不完全一致，因此只将其作为当前适配实现的参考。

Accuracy 为 72 类完全命中率。预测类别 $\hat{y}$ 先映射为 $\hat{\theta} = -180^{\circ} + 5^{\circ}\hat{y}$ ，再计算环形角距离

$$d_{\text{circ}} = \left| ((\hat{\theta} - \theta + 180^{\circ}) \bmod 360^{\circ}) - 180^{\circ} \right|. \quad (9)$$

MAE 为 d_{circ} 的样本均值，衡量离散类别预测的圆周角误差，不代表连续回归精度。复杂度以参数量、MACs 和 FLOPs 报告。

4.2. 不同 SNR 下的定位性能

表 1 比较五个含噪条件，以观察噪声增强时的退化趋势。所提模型的准确率从 10 dB 下的 98.89% 降至 -10 dB 下的 90.15%，MAE 由 0.87° 增至 6.30° 。SDEL-style 在多数条件下具有更强的绝对性能；所提模型则在全部 SNR 上均优于当前 DP-RTF-style 与 BiL-style 的准确率和 MAE。相对 FN-SSL-style 不存在覆盖所有条件的一致优势，因此证据支持的是渐进退化和性能-效率权衡，而非定位精度最优。

4.3. 性能-复杂度权衡

表 2 比较完整测试集结果与复杂度。所提模型是当前比较中参数量、MACs 和 FLOPs 最低的模型。相较 SDEL-style，其参数量和 FLOPs 分别减少 83.5% 和 72.1%，代价是准确率低 0.67 个百分点、MAE 高 0.28° ；相较 FN-SSL-style，其 FLOPs 约为 1/168，准确率低 0.24 个百分点、MAE 高 0.13° 。这些结果支持紧凑性，但低 FLOPs 不能替代尚未测量的目标硬件延迟、内存和能耗。

4.4. 消融实验

表 3 检验三类结构分解。移除幅度谱上下文流后，准确率下降 0.56 个百分点且 MAE 增加 0.48° ，说明显式 ILD/IPD 之外仍存在互补的幅度谱上下文。移除相干性分支后，两项变化分别为 -0.55 个百分点和 $+0.49^{\circ}$ ，支持独立相干性编码在当前组合中有益。将方向线索与相干性送入同一个合并编码器后，MAE 增加 0.59° ，表明分离编码优于所测试的合并实现。由于尚无配对显著性检验，本文不将这些差异描述为统计显著。

三项消融形成一条相互约束的证据链。无幅度谱上下文的线索模型仍达到 95.95% 准确率，说明显式 ILD/IPD 已承担大部分方向判别；加入幅度谱上下文与相干性后，完整模型进一步降低圆周角误差，表明三类输入并非完全冗余；合并线索编码未带来更低误差，则支持在当前预算与对照范围内先保持线索结构、再低维融合。该解释描述观察到的模型行为，不等于证明每个分支内部恢复了预设声学变量。

当前测试协议存在语音划分限制：6,784 个唯一测试语音路径中有 4,868 个也出现在训练集。方位标签由独立声学渲染产生，因而该现象不等于已证实的标签泄漏；但它阻止本文声称说话人或语句无关泛化。完整的 speech-disjoint 基线与消融重训仍在进行，本文不混用尚未闭环的新协议结果。

5. 结论

本文面向双耳 360° 水平 DOA 分类，研究如何按照线索结构分配有限表示容量。方法以共享编码器组织两耳幅度谱关系，以低维分支分别处理 ILD/IPD 方向线索与耳间相干性，再以 112 维表示和单层 BiGRU 完成片段级融合。在当前模拟 KEMAR 静态协议上，模型以 0.153 M 参数和 0.391 GFLOPs 取得 96.51% 准确率与 2.46° 环形 MAE。复杂度对比支持其性能-效率工作点，消融则显示显式线索承担主要方向判别，幅度谱上下文与相干性提供互补信息，分离编码优于所测合并实现。当前结论受固定 KEMAR、模拟环境和语音路径重叠限制，不能外推到未见 HRTF、真实录音、移动声源或实时部署。后续首先完成 speech-disjoint 全套评测，再引入实测 BRIR 与目标设备延迟验证。

6. REFERENCES

- [1] Jens Blauert, *Spatial Hearing: The Psychophysics of Human Sound Localization*, MIT Press, Cambridge, MA, revised edition, 1997.

- [2] Tobias May, Steven van de Par, and Armin Kohlrausch, "A probabilistic model for robust localization based on a binaural auditory front-end," *IEEE Transactions on Audio, Speech, and Language Processing*, vol. 19, no. 1, pp. 1–13, 2011.
- [3] Paolo Vecchiotti, Ning Ma, Stefano Squartini, and Guy J. Brown, "End-to-end binaural sound localisation from the raw waveform," in *Proc. IEEE ICASSP*, 2019, pp. 451–455.
- [4] Charles H. Knapp and G. Clifford Carter, "The generalized correlation method for estimation of time delay," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 24, no. 4, pp. 320–327, 1976.
- [5] Vikas Tokala, Eric Grinstein, Rory Brooks, Mike Brookes, Simon Doclo, Jesper Jensen, and Patrick A. Naylor, "Binaural localization model for speech in noise," *arXiv preprint arXiv:2507.20027*, 2025.
- [6] Vassil Panayotov, Guoguo Chen, Daniel Povey, and Sanjeev Khudanpur, "Librispeech: An asr corpus based on public domain audio books," in *Proc. IEEE ICASSP*, 2015, pp. 5206–5210.
- [7] William G. Gardner and Keith D. Martin, "Hrtf measurements of a kemar," *The Journal of the Acoustical Society of America*, vol. 97, pp. 3907–3908, 1995.
- [8] Roberto Barumerli, Daniele Bianchi, Michele Geronazzo, and Federico Avanzini, "Sofamyroom: A fast and multiplatform shoebox room simulator for binaural room impulse response dataset generation," *arXiv preprint arXiv:2106.12992*, 2021.
- [9] Joachim Thiemann, Nobutaka Ito, and Emmanuel Vincent, "The diverse environments multi-channel acoustic noise database (demand): A database of multichannel environmental noise recordings," in *Proc. Meetings on Acoustics*, 2013, p. 035081.